Segmentação Semântica de Cenas Urbanas com Cityscapes: Uma Análise Comparativa de Modelos de Aprendizagem Profunda

Importações e Downloads

```
import os
import cv2
import time
import random
import numpy as np
import pandas as pd
from PIL import Image
from tqdm import tqdm
import tensorflow as tf
from tensorflow import keras
import matplotlib.pyplot as plt
import matplotlib.image as mpimg
from tensorflow.keras import layers, models
from tensorflow.keras.models import Model
from tensorflow.keras.applications import MobileNetV2, ResNet50
from sklearn.model_selection import train_test_split, ShuffleSplit
from tensorflow.keras.layers import Input, Conv2D, MaxPooling2D, Conv2DTranspose, concatenate, UpS
```

Análise de Dados

```
from google.colab import drive
drive.mount('/content/drive')
```

```
Drive already mounted at /content/drive; to attempt to forcibly remount, call drive.mount("/conte
```

Organização do Diretório

```
pasta_cityscape = "/content/drive/MyDrive/Colab Notebooks/Introdução à Aprendizagem Profunda/citys
print(sorted(os.listdir(pasta_cityscape)))
```

```
['gtFine_trainvaltest', 'leftImg8bit_trainvaltest']
```

```
pasta_gtFine = pasta_cityscape + "/gtFine_trainvaltest/gtFine"
pasta_leftImg8bit = pasta_cityscape + "/leftImg8bit_trainvaltest/leftImg8bit"

print(sorted(os.listdir(pasta_leftImg8bit)))
print(sorted(os.listdir(pasta_gtFine)))
```

```
['test', 'train', 'val']
['test', 'train', 'val']
```

```
pasta_gtFine_train = pasta_gtFine + "/train"
pasta_gtFine_val = pasta_gtFine + "/val"
```

```
pasta_gtFine_test = pasta_gtFine + "/test"

print(sorted(os.listdir(pasta_gtFine_train)))
print(sorted(os.listdir(pasta_gtFine_val)))
print(sorted(os.listdir(pasta_gtFine_test)))
```

```
['aachen', 'bochum', 'bremen', 'cologne', 'darmstadt', 'dusseldorf', 'erfurt', 'hamburg', 'hanove
['frankfurt', 'lindau', 'munster']
['berlin', 'bielefeld', 'bonn', 'leverkusen', 'mainz', 'munich']
```

```
pasta_leftImg8bit_train = pasta_leftImg8bit + "/train"
pasta_leftImg8bit_val = pasta_leftImg8bit + "/val"
pasta_leftImg8bit_test = pasta_leftImg8bit + "/test"

print(sorted(os.listdir(pasta_leftImg8bit_train)))
print(sorted(os.listdir(pasta_leftImg8bit_val)))
print(sorted(os.listdir(pasta_leftImg8bit_test)))
```

```
['aachen', 'bochum', 'bremen', 'cologne', 'darmstadt', 'dusseldorf', 'erfurt', 'hamburg', 'hanove
['frankfurt', 'lindau', 'munster']
['berlin', 'bielefeld', 'bonn', 'leverkusen', 'mainz', 'munich']
```

```
print(sorted(os.listdir(pasta_gtFine_train + "/aachen")))
print(sorted(os.listdir(pasta_gtFine_val + "/frankfurt")))
print(sorted(os.listdir(pasta_gtFine_test + "/berlin")))
print("\n")
print(sorted(os.listdir(pasta_leftImg8bit_train + "/aachen")))
print(sorted(os.listdir(pasta_leftImg8bit_val + "/frankfurt")))
print(sorted(os.listdir(pasta_leftImg8bit_test + "/berlin")))
```

As imagens do conjunto de dados Cityscapes são organizadas em dois principais diretórios: `gtFine` e `leftImg8bit`. Dentro desses diretórios, o conjunto de dados é subdividido em conjuntos de treinamento, validação e teste. Além disso, cada subconjunto é categorizado por cidade, refletindo diversas cidades urbanas, principalmente da Alemanha, nas quais as imagens foram coletadas.

Dentro da pasta `gtFine`, as imagens estão disponíveis em quatro formatos distintos, cada um com um propósito específico:

1. **gtFine_color**: Este formato representa as imagens coloridas originais, preservando informações de cor e textura. É útil para tarefas gerais de análise visual, como identificação de objetos, navegação de robôs autônomos ou qualquer aplicação em que a cor e os detalhes visuais sejam essenciais.
2. **gtFine_instanceIds**: Aqui, as imagens contêm informações de identificação de instância, permitindo a segmentação de objetos individuais dentro da cena. É ideal para tarefas de segmentação de instâncias, onde o objetivo é separar e identificar objetos individuais, como carros, pedestres ou bicicletas, em uma cena.
3. **gtFine_labelIds**: As imagens neste formato são usadas para a tarefa de segmentação semântica e atribuem um rótulo de classe a cada pixel, indicando a categoria semântica à qual o pixel pertence (por exemplo, carro, estrada, edifício). É apropriado para tarefas de segmentação semântica, onde o objetivo é rotular cada pixel em uma imagem com sua categoria semântica correspondente. Isso é útil em aplicações como mapeamento urbano, análise de tráfego, entre outras.
4. **gtFine_polygons (json)**: Este formato contém informações de segmentação poligonal em formato JSON, que descrevem os contornos das áreas de objetos na imagem. É adequado para tarefas de

segmentação baseadas em contornos ou para análise mais detalhada da forma de objetos. Também pode ser útil para extrair informações geométricas precisas.

A divisão por cidade e a presença de quatro tipos de imagens (color, instanceIds, labelIds, polygons) permitem uma variedade de tarefas de visão computacional, como segmentação semântica, segmentação de instâncias e análise detalhada de objetos dentro da cena urbana.

Análise das imagens

```
img_gtFine_color = mpimg.imread(pasta_gtFine_train + "/aachen/aachen_000000_000019_gtFine_color.p
img_gtFine_instanceIds = mpimg.imread(pasta_gtFine_train + "/aachen/aachen_000000_000019_gtFine_i
img_gtFine_labelIds = mpimg.imread(pasta_gtFine_train + "/aachen/aachen_000000_000019_gtFine_labe
json_gtFine_polygons = (pasta_gtFine_train + "/aachen/aachen_000000_000019_gtFine_polygons.json")
img_leftImg8bit = mpimg.imread(pasta_leftImg8bit_train + "/aachen/aachen_000000_000019_leftImg8bi

fig, axs = plt.subplots(2, 2, figsize=(10, 10))

axs[0, 0].set_title('gtFine_color')
axs[0, 1].set_title('gtFine_instanceIds')
axs[1, 0].set_title('gtFine_labelIds')
axs[1, 1].set_title('leftImg8bit')

axs[0, 0].imshow(img_gtFine_color)
axs[0, 1].imshow(img_gtFine_instanceIds)
axs[1, 0].imshow(img_gtFine_labelIds)
axs[1, 1].imshow(img_leftImg8bit)

plt.tight_layout()
plt.show()
```


```
img_gtFine_color = mpimg.imread(pasta_gtFine_val + "/frankfurt/frankfurt_000000_000294_gtFine_colo
img_gtFine_instanceIds = mpimg.imread(pasta_gtFine_val + "/frankfurt/frankfurt_000000_000294_gtFir
img_gtFine_labelIds = mpimg.imread(pasta_gtFine_val + "/frankfurt/frankfurt_000000_000294_gtFine_l
json_gtFine_polygons = (pasta_gtFine_val + "/frankfurt/frankfurt_000000_000294_gtFine_polygons.jso
img_leftImg8bit = mpimg.imread(pasta_leftImg8bit_val + "/frankfurt/frankfurt_000000_000294_leftImg

fig, axs = plt.subplots(2, 2, figsize=(10, 10))

axs[0, 0].set_title('gtFine_color')
axs[0, 1].set_title('gtFine_instanceIds')
axs[1, 0].set_title('gtFine_labelIds')
axs[1, 1].set_title('leftImg8bit')

axs[0, 0].imshow(img_gtFine_color)
axs[0, 1].imshow(img_gtFine_instanceIds)
axs[1, 0].imshow(img_gtFine_labelIds)
axs[1, 1].imshow(img_leftImg8bit)

plt.tight_layout()
plt.show()
```

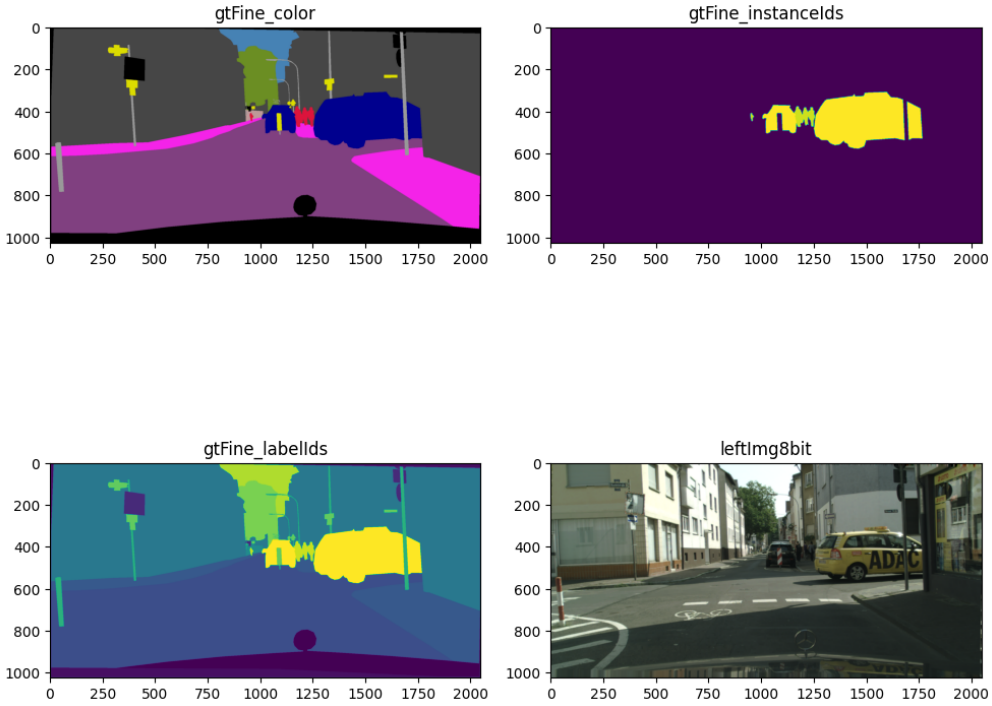


```
img_gtFine_color = mpimg.imread(pasta_gtFine_test + "/berlin/berlin_000000_000019_gtFine_color.png
img_gtFine_instanceIds = mpimg.imread(pasta_gtFine_test + "/berlin/berlin_000000_000019_gtFine_ins
img_gtFine_labelIds = mpimg.imread(pasta_gtFine_test + "/berlin/berlin_000000_000019_gtFine_labelI
json_gtFine_polygons = (pasta_gtFine_test + "/berlin/berlin_000000_000019_gtFine_polygons.json")
img_leftImg8bit = mpimg.imread(pasta_leftImg8bit_test + "/berlin/berlin_000000_000019_leftImg8bit.
```

```
fig, axs = plt.subplots(2, 2, figsize=(10, 10))

axs[0, 0].set_title('gtFine_color')
axs[0, 1].set_title('gtFine_instanceIds')
axs[1, 0].set_title('gtFine_labelIds')
axs[1, 1].set_title('leftImg8bit')

axs[0, 0].imshow(img_gtFine_color)
axs[0, 1].imshow(img_gtFine_instanceIds)
axs[1, 0].imshow(img_gtFine_labelIds)
axs[1, 1].imshow(img_leftImg8bit)

plt.tight_layout()
plt.show()
```

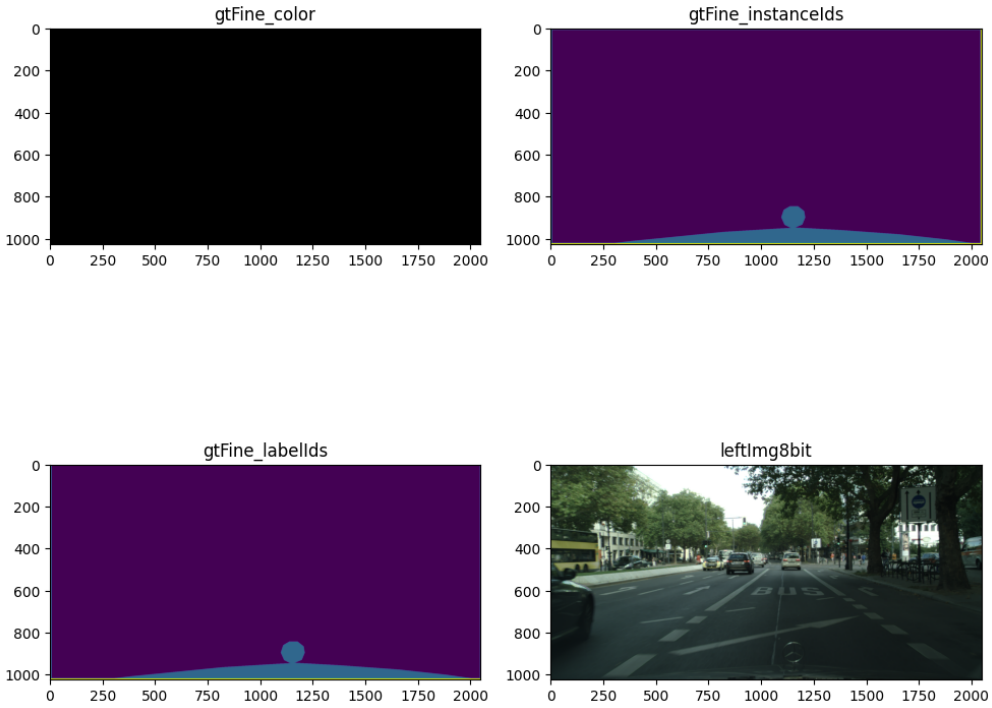

As imagens no conjunto de teste não estão com a segmentação devida, como no de treino e validação.

Caminho dos Dados

```
def get_paths(gtFine, leftImg8bit, pasta):
  labels_path = os.path.join(gtFine, pasta)
  images_path = os.path.join(leftImg8bit, pasta)
  label_files = [os.path.join(labels_path,arq) for arq in os.listdir(labels_path) if 'gtFine_label
  img_files = [os.path.join(images_path,arq) for arq in os.listdir(images_path) if 'leftImg8bit' i
  paths = list(zip(sorted(img_files), sorted(label_files)))
  return paths
```

```
path_list = []

for pasta in tqdm(os.listdir(pasta_gtFine_train)):
  path_list += get_paths(pasta_gtFine_train, pasta_leftImg8bit_train, pasta)

for pasta in tqdm(os.listdir(pasta_gtFine_val)):
  path_list += get_paths(pasta_gtFine_val, pasta_leftImg8bit_val, pasta)
```

```
100%|██████████| 18/18 [00:03<00:00,  4.81it/s]
100%|██████████| 3/3 [00:00<00:00,  9.82it/s]
```

```
len(path_list)
```

```
3475
```

```
def print_img(path_list):
  fig, axs = plt.subplots(4, 2, figsize=(10, 10))

  for i in range(4):
    random_num = random.randint(0, len(path_list) - 1)
    axs[i, 0].imshow(mpimg.imread(path_list[random_num][0]))
    axs[i, 1].imshow(mpimg.imread(path_list[random_num][1]))

  plt.tight_layout()
  plt.show()
```

```
print_img(path_list)
```

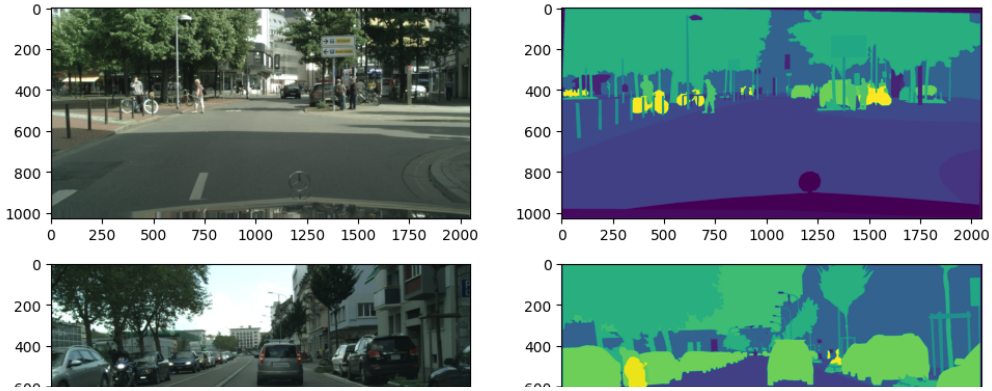

Divisão dos dados

```
images = []
labels = []

for image_path, label_path in tqdm(path_list[:500]):
  image = cv2.imread(image_path)
  image = cv2.resize(image, (256, 256))
  image = image / 255.0
  label = cv2.imread(label_path, cv2.IMREAD_GRAYSCALE)
  label = cv2.resize(label, (256, 256), interpolation=cv2.INTER_NEAREST)

  images.append(np.array(image))
  labels.append(np.array(label))

X_train, X_temp, y_train, y_temp = train_test_split(images, labels, test_size=0.3, random_state=42
X_val, X_test, y_val, y_test = train_test_split(X_temp, y_temp, test_size=0.5, random_state=42)

X_train = np.array(X_train)
X_val = np.array(X_val)
X_test = np.array(X_test)
y_train = np.array(y_train)
y_val = np.array(y_val)
y_test = np.array(y_test)

X_train.shape, X_val.shape, X_test.shape, y_train.shape, y_val.shape, y_test.shape
```

```
100%|██████████| 500/500 [01:09<00:00,  7.19it/s]
((350, 256, 256, 3),
 (75, 256, 256, 3),
 (75, 256, 256, 3),
 (350, 256, 256),
 (75, 256, 256),
 (75, 256, 256))
```

```
from sklearn.preprocessing import normalize
x = np.expand_dims(X_train, axis=3)
train_x_norm = normalize(x.reshape(x.shape[0],-1), axis=1).reshape(x.shape)
train_y_norm = np.expand_dims(y_train, axis=3)

y = np.expand_dims(X_test, axis=3)
test_x_norm = normalize(y.reshape(y.shape[0],-1), axis=1).reshape(y.shape)
test_y_norm = np.expand_dims(y_test, axis=3)

z = np.expand_dims(X_val, axis=3)
val_x_norm = normalize(z.reshape(z.shape[0],-1), axis=1).reshape(z.shape)
val_y_norm = np.expand_dims(y_val, axis=3)
```

```
n_classes = np.max(labels) + 1

train_y_cat = keras.utils.to_categorical(train_y_norm, num_classes=n_classes)
val_y_cat = keras.utils.to_categorical(val_y_norm, num_classes=n_classes)
test_y_cat = keras.utils.to_categorical(test_y_norm, num_classes=n_classes)
```

Funções Comuns

```
def fit_model(model):
  start_time = time.time()
  model.compile(optimizer='adam', loss='categorical_crossentropy', metrics=['accuracy'])
  history = model.fit(X_train, train_y_cat, validation_data=(X_val, val_y_cat), batch_size=32, epo
  end_time = time.time()
  elapsed_time = end_time - start_time
  return elapsed_time

def eval_model(model):
  test_loss, test_accuracy = model.evaluate(X_test, test_y_cat)
  predictions = model.predict(X_test)

  true_positive = (predictions * test_y_cat).sum()
  false_positive = predictions.sum() - true_positive
  precision = true_positive / (true_positive + false_positive)

  correct_pixels = (predictions == test_y_cat).sum()
  total_pixels = predictions.size
  pixel_accuracy = correct_pixels / total_pixels

  intersection = (predictions * test_y_cat).sum(axis=(1, 2, 3))
  union = (predictions + test_y_cat - (predictions * test_y_cat)).sum(axis=(1, 2, 3))
  iou = (intersection / union).mean()

  class_iou = intersection / union
  mIoU = class_iou.mean()

  class_iou_dict = {}
  print("IoU por Classe:")
  for i in range(n_classes):
      class_iou_dict[f'Classe {i}'] = class_iou[:, i]
      print(f"Classe {i}: {class_iou[:, i]}")

  print(f'Test Loss: {test_loss}, Test Accuracy: {test_accuracy}')
  print(f'Precision: {precision}, Pixel Accuracy: {pixel_accuracy}')
  print(f'Intersection over Union (IoU): {iou}')
  print(f'Mean IoU (mIoU): {mIoU}')

  return class_iou_dict

def seg_sample(model):
  predictions = model.predict(X_test)
  fig, axs = plt.subplots(4, 3, figsize=(10, 10))

  predictions_resized = np.argmax(predictions, axis=-1)
  test_y_resized = np.argmax(test_y_cat, axis=-1)

  for i in range(4):
    random_num = random.randint(0, len(predictions) - 1)
    axs[i, 0].set_title('Original Image')
```

```
    axs[i, 1].set_title('True Mask')
    axs[i, 2].set_title('Predicted Mask')

    axs[i, 0].imshow(X_test[random_num])
    axs[i, 1].imshow(test_y_resized[random_num])
    axs[i, 2].imshow(predictions_resized[random_num])

  plt.tight_layout()
  plt.show()
```

U-Net

A U-Net e um dos modelos mais populares para segmentação semântica devido à sua arquitetura encoder-decoder com conexões residuais. A estrutura em formato de U permite que informações de níveis de resolução mais altos sejam transmitidas para a fase de decodificação, o que facilita a recuperação de detalhes importantes na etapa de segmentação.

- Arquitetura em forma de U: A UNet tem uma arquitetura em forma de U, composta por uma metade descendente (encoder) e uma metade ascendente (decoder). Essa forma de U permite que a rede capture informações contextuais em diferentes escalas e, em seguida, as combine para produzir uma segmentação precisa.
- Camadas de convolução: A UNet usa camadas de convolução para extrair características das imagens de entrada. O encoder consiste em várias camadas de convolução para reduzir a resolução espacial e aumentar a representação semântica das características.
- Camadas de pooling: Entre as camadas de convolução do encoder, a UNet geralmente utiliza camadas de pooling (normalmente max-pooling) para reduzir ainda mais a resolução espacial e aumentar o campo receptivo das camadas convolucionais subsequentes.
- Conexões skip: Uma característica importante da UNet é a utilização de conexões skip entre as camadas do encoder e do decoder. Isso permite que as características de baixo nível do encoder sejam diretamente combinadas com as características de alto nível do decoder, o que ajuda a preservar informações detalhadas durante a fase de up-sampling.
- Função de ativação: A UNet frequentemente usa funções de ativação como ReLU (Rectified Linear Unit) para introduzir não-linearidade nas camadas convolucionais.
- Função de perda: A função de perda usada comumente na UNet depende da tarefa específica, mas em tarefas de segmentação, a perda Dice ou a perda de entropia cruzada são frequentemente usadas.

```
def conv_block(x, filters, kernel_size=3):
    x = Conv2D(filters, kernel_size, activation='relu', padding='same')(x)
    x = Conv2D(filters, kernel_size, activation='relu', padding='same')(x)
    return x

def decoder_block(x, skip_connection, filters, kernel_size=3):
    x = UpSampling2D((2, 2))(x)
    x = concatenate([x, skip_connection], axis=-1)
    x = conv_block(x, filters, kernel_size)
    return x

def unet(input_shape, n_classes):
    inputs = Input(input_shape)
```

```
    # Encoder
    encoder_blocks = []
    x = inputs
    for filters in [64, 128, 256, 512]:
        x = conv_block(x, filters)
        encoder_blocks.append(x)
        x = MaxPooling2D(pool_size=(2, 2))(x)

    # Bottleneck
    x = conv_block(x, 1024)

    # Decoder
    for filters, skip_connection in zip([512, 256, 128, 64], encoder_blocks[::-1]):
        x = decoder_block(x, skip_connection, filters)

    outputs = Conv2D(n_classes, 1, activation='softmax')(x)
    model = tf.keras.Model(inputs=inputs, outputs=outputs)
    return model

model = unet((256, 256, 3), n_classes)
model.summary()

# model.save('segmentation_model.h5')
```

```
Model: "model"
_________________________________________________________________________________________________
 Layer (type)                Output Shape              Param #   Connected to
=================================================================================================
 input_3 (InputLayer)        [(None, 256, 256, 3)]     0         []

 conv2d_11 (Conv2D)          (None, 256, 256, 64)      1792      ['input_3[0][0]']

 conv2d_12 (Conv2D)          (None, 256, 256, 64)      36928     ['conv2d_11[0][0]']

 max_pooling2d_3 (MaxPoolin  (None, 128, 128, 64)      0         ['conv2d_12[0][0]']
 g2D)

 conv2d_13 (Conv2D)          (None, 128, 128, 128)     73856     ['max_pooling2d_3[0][0]']

 conv2d_14 (Conv2D)          (None, 128, 128, 128)     147584    ['conv2d_13[0][0]']

 max_pooling2d_4 (MaxPoolin  (None, 64, 64, 128)       0         ['conv2d_14[0][0]']
 g2D)

 conv2d_15 (Conv2D)          (None, 64, 64, 256)       295168    ['max_pooling2d_4[0][0]']

 conv2d_16 (Conv2D)          (None, 64, 64, 256)       590080    ['conv2d_15[0][0]']

 max_pooling2d_5 (MaxPoolin  (None, 32, 32, 256)       0         ['conv2d_16[0][0]']
 g2D)

 conv2d_17 (Conv2D)          (None, 32, 32, 512)       1180160   ['max_pooling2d_5[0][0]']

 conv2d_18 (Conv2D)          (None, 32, 32, 512)       2359808   ['conv2d_17[0][0]']

 max_pooling2d_6 (MaxPoolin  (None, 16, 16, 512)       0         ['conv2d_18[0][0]']
 g2D)

 conv2d_19 (Conv2D)          (None, 16, 16, 1024)      4719616   ['max_pooling2d_6[0][0]']

 conv2d_20 (Conv2D)          (None, 16, 16, 1024)      9438208   ['conv2d_19[0][0]']

 up_sampling2d_3 (UpSamplin  (None, 32, 32, 1024)      0         ['conv2d_20[0][0]']
 g2D)
```

```
concatenate_3 (Concatenate  (None, 32, 32, 1536)        0         ['up_sampling2d_3[0][0]',
)                                                                   'conv2d_18[0][0]']

conv2d_21 (Conv2D)          (None, 32, 32, 512)         7078400   ['concatenate_3[0][0]']

conv2d_22 (Conv2D)          (None, 32, 32, 512)         2359808   ['conv2d_21[0][0]']

up_sampling2d_4 (UpSamplin  (None, 64, 64, 512)         0         ['conv2d_22[0][0]']
g2D)

concatenate_4 (Concatenate  (None, 64, 64, 768)         0         ['up_sampling2d_4[0][0]',
)                                                                   'conv2d_16[0][0]']

conv2d_23 (Conv2D)          (None, 64, 64, 256)         1769728   ['concatenate_4[0][0]']

conv2d_24 (Conv2D)          (None, 64, 64, 256)         590080    ['conv2d_23[0][0]']
```

```
elapsed_time = fit_model(model)
unet_class_iou_dict = eval_model(model)
print(f'Time Elapsed: {elapsed_time}')
seg_sample(model)
```

SegNet

O modelo SegNet também utiliza uma arquitetura encoder-decoder, mas com uma abordagem mais leve em relação a U-Net. Essa arquitetura foi projetada especificamente para a tarefa de segmentação semântica e busca um equilíbrio entre desempenho e eficiência computacional.

- Encoder-Decoder Arquitetura: O SegNet adota uma arquitetura do tipo encoder-decoder, onde o encoder (codificador) é responsável por extrair características das imagens de entrada e o decoder (decodificador) reconstrói a segmentação a partir dessas características.
- Redução de Resolução Espacial: O encoder utiliza camadas de convolução para reduzir a resolução espacial das imagens de entrada. Isso é feito através de camadas de convolução e pooling, semelhante a muitas outras arquiteturas de segmentação.
- Uso de Max-Pooling com Pooling Indices: Uma característica distintiva do SegNet é que ele armazena os índices dos valores máximos durante as camadas de pooling. Isso permite que o decoder use esses índices para reconstruir a resolução espacial nas camadas de up-sampling (convolução transposta).
- Camadas de Up-Sampling: O decoder do SegNet utiliza camadas de up-sampling (convolução transposta) para aumentar a resolução espacial das características. Os índices de pooling armazenados são usados para realizar up-sampling reverso, o que ajuda a reconstruir a segmentação com detalhes espaciais precisos.
- Funções de Ativação: O SegNet normalmente usa funções de ativação, como ReLU, para introduzir não-linearidade nas camadas convolucionais.
- Função de Perda: A função de perda usada no SegNet depende da tarefa específica, mas, assim como na UNet, a perda de entropia cruzada é frequentemente usada para tarefas de segmentação.

```
def create_segnet(input_shape, n_classes):
    inputs = Input(shape=input_shape)

```

```
    conv1 = Conv2D(64, (3, 3), padding='same', activation='relu')(inputs)
    bn1 = BatchNormalization()(conv1)
    pool1, mask1 = MaxPoolingWithArgmax2D((2, 2))(bn1)

    conv2 = Conv2D(128, (3, 3), padding='same', activation='relu')(pool1)
    bn2 = BatchNormalization()(conv2)
    pool2, mask2 = MaxPoolingWithArgmax2D((2, 2))(bn2)

    conv3 = Conv2D(256, (3, 3), padding='same', activation='relu')(pool2)
    bn3 = BatchNormalization()(conv3)
    pool3, mask3 = MaxPoolingWithArgmax2D((2, 2))(bn3)

    up1 = UpSampling2D((2, 2))(pool3)
    conv4 = Conv2D(256, (3, 3), padding='same', activation='relu')(up1)

    up2 = UpSampling2D((2, 2))(conv4)
    conv5 = Conv2D(128, (3, 3), padding='same', activation='relu')(up2)

    up3 = UpSampling2D((2, 2))(conv5)

    unpool1 = MaxUnpooling2D()([up3, mask3])
    unpool2 = MaxUnpooling2D()([unpool1, mask2])
    unpool3 = MaxUnpooling2D()([unpool2, mask1])

    outputs = Conv2D(n_classes, (3, 3), padding='same', activation='softmax')(unpool3)

    model = Model(inputs, outputs)
    return model

class MaxPoolingWithArgmax2D(Layer):
    def __init__(self, pool_size=(2, 2), **kwargs):
        super(MaxPoolingWithArgmax2D, self).__init__(**kwargs)
        self.pool_size = pool_size

    def call(self, inputs, **kwargs):
        pool_size = self.pool_size
        if K.backend() == 'tensorflow':
            ksize = [1, pool_size[0], pool_size[1], 1]
            padding = 'VALID'
            strides = [1, pool_size[0], pool_size[1], 1]
            output, argmax = tf.nn.max_pool_with_argmax(inputs, ksize, strides, padding)
        else:
            errmsg = 'MaxPoolingWithArgmax2D supports only TensorFlow backend.'
            raise NotImplementedError(errmsg)
        argmax = K.cast(argmax, K.floatx())
        return [output, argmax]

    def compute_output_shape(self, input_shape):
        ratio = (1, 2, 2, 1)
        output_shape = [dim // ratio[idx % 2] if dim is not None else None for idx, dim in enumera
        output_shape = tuple(output_shape)
        return [output_shape, output_shape]

    def compute_mask(self, inputs, mask=None):
        return 2 * [None]

class MaxUnpooling2D(Layer):
    def call(self, inputs, output_shape=None):
        updates, mask = inputs[0], inputs[1]
        with tf.variable_scope(self.name):
            mask = tf.cast(mask, 'int32')
            input_shape = tf.shape(updates, out_type='int32')
```

```
            output_shape = tf.cast(output_shape, 'int32')
            one_like_mask = tf.ones_like(mask, dtype='int32')
            batch_shape = tf.concat([[input_shape[0]], [1], [1], [1]], axis=0)
            batch_range = tf.reshape(tf.range(input_shape[0], dtype='int32'), shape=batch_shape)
            b = one_like_mask * batch_range
            y = mask // (output_shape[2] * output_shape[3])
            x = (mask // output_shape[3]) % output_shape[2]
            feature_range = tf.range(output_shape[3], dtype='int32')
            f = one_like_mask * feature_range
            updates_size = tf.size(updates)
            indices = tf.transpose(tf.reshape(tf.stack([b, y, x, f]), [4, updates_size]))
            values = tf.reshape(updates, [updates_size])
            ret = tf.scatter_nd(indices, values, output_shape)
            return ret

    def compute_output_shape(self, input_shape):
        mask_shape = input_shape[1]
        return (
            (mask_shape[0], mask_shape[1], mask_shape[2], mask_shape[3]),
        )

model = create_segnet((256, 256, 3))
model.summary()
```

```
def create_segnet(input_shape):
  inputs = Input(shape=input_shape)

  conv1 = Conv2D(64, (3, 3), padding='same', activation='relu')(inputs)
  bn1 = BatchNormalization()(conv1)
  pool1 = MaxPooling2D((2, 2))(bn1)

  conv2 = Conv2D(128, (3, 3), padding='same', activation='relu')(pool1)
  bn2 = BatchNormalization()(conv2)
  pool2 = MaxPooling2D((2, 2))(bn2)

  conv3 = Conv2D(256, (3, 3), padding='same', activation='relu')(pool2)
  bn3 = BatchNormalization()(conv3)
  pool3 = MaxPooling2D((2, 2))(bn3)

  up1 = UpSampling2D((2, 2))(pool3)
  conv4 = Conv2D(256, (3, 3), padding='same', activation='relu')(up1)

  up2 = UpSampling2D((2, 2))(conv4)
  conv5 = Conv2D(128, (3, 3), padding='same', activation='relu')(up2)

  up3 = UpSampling2D((2, 2))(conv5)

  outputs = Conv2D(n_classes, (3, 3), padding='same', activation='softmax')(up3)

  model = Model(inputs, outputs)
  return model

model = create_segnet((256, 256, 3))
model.summary()
```

```
Model: "model_5"
_________________________________________________________________
 Layer (type)                Output Shape              Param #
=================================================================
 input_12 (InputLayer)       [(None, 256, 256, 3)]     0

 conv2d_62 (Conv2D)          (None, 256, 256, 64)      1792
```

```
batch_normalization_5 (Bat  (None, 256, 256, 64)      256
chNormalization)

max_pooling2d_11 (MaxPooli  (None, 128, 128, 64)      0
ng2D)

conv2d_63 (Conv2D)          (None, 128, 128, 128)     73856

batch_normalization_6 (Bat  (None, 128, 128, 128)     512
chNormalization)

max_pooling2d_12 (MaxPooli  (None, 64, 64, 128)       0
ng2D)

conv2d_64 (Conv2D)          (None, 64, 64, 256)       295168

batch_normalization_7 (Bat  (None, 64, 64, 256)       1024
chNormalization)

max_pooling2d_13 (MaxPooli  (None, 32, 32, 256)       0
ng2D)

up_sampling2d_14 (UpSampli  (None, 64, 64, 256)       0
ng2D)

conv2d_65 (Conv2D)          (None, 64, 64, 256)       590080

up_sampling2d_15 (UpSampli  (None, 128, 128, 256)     0
ng2D)

conv2d_66 (Conv2D)          (None, 128, 128, 128)     295040

up_sampling2d_16 (UpSampli  (None, 256, 256, 128)     0
ng2D)

conv2d_67 (Conv2D)          (None, 256, 256, 34)      39202

=================================================================
Total params: 1296930 (4.95 MB)
Trainable params: 1296034 (4.94 MB)
Non-trainable params: 896 (3.50 KB)
_________________________________________________________________
```

```
elapsed_time = fit_model(model)
segnet_class_iou_dict = eval_model(model)
print(f'Time Elapsed: {elapsed_time}')
seg_sample(model)
```

FCN

O modelo FCN (Fully Convolutional Network) é uma arquitetura que transforma redes neurais convolucionais profundas em modelos para segmentação semântica. Ele permite a preservação da resolução espacial durante o processo de convolução, capturando informações contextuais em várias escalas.

- Camadas Convolucionais Completas: Ao contrário das arquiteturas tradicionais de CNN, as FCNs consistem principalmente em camadas convolucionais sem camadas densas (fully connected). Isso permite que a rede aceite imagens de qualquer tamanho de entrada e produza um mapa de segmentação do mesmo tamanho da entrada.

- Convoluções 1x1: As FCNs frequentemente utilizam convoluções 1x1 para reduzir a dimensionalidade das características e, ao mesmo tempo, aumentar o número de canais (ou classes de segmentação). Isso é útil para a fusão de informações de diferentes camadas e tamanhos de campo receptivo.
- Camadas de Up-Sampling: As FCNs incluem camadas de up-sampling (convolução transposta) para aumentar a resolução espacial do mapa de segmentação de saída para que ele corresponda ao tamanho da imagem de entrada.
- Fusão de Camadas de Diferentes Resoluções: Uma característica crítica das FCNs é a fusão de informações de diferentes camadas convolucionais para capturar detalhes de diferentes escalas. Isso geralmente é feito por meio de conexões skip, onde informações de camadas mais profundas são fundidas com informações de camadas menos profundas para obter uma segmentação precisa.
- Função de Ativação Softmax: A camada de saída das FCNs geralmente usa uma função de ativação softmax para atribuir probabilidades de pertencimento a cada classe de segmentação para cada pixel.
- Uso de Funções de Perda Específicas: Para tarefas de segmentação semântica, as FCNs frequentemente usam funções de perda, como a entropia cruzada, para comparar as previsões do modelo com as anotações da imagem de treinamento.

```
def create_fcn(input_shape):
  inputs = Input(shape=input_shape)

  conv1 = Conv2D(64, (3, 3), activation='relu', padding='same')(inputs)
  conv1 = Conv2D(64, (3, 3), activation='relu', padding='same')(conv1)
  maxpool1 = MaxPooling2D((2, 2), strides=(2, 2))(conv1)

  conv2 = Conv2D(128, (3, 3), activation='relu', padding='same')(maxpool1)
  conv2 = Conv2D(128, (3, 3), activation='relu', padding='same')(conv2)
  maxpool2 = MaxPooling2D((2, 2), strides=(2, 2))(conv2)

  conv3 = Conv2D(256, (3, 3), activation='relu', padding='same')(maxpool2)
  conv3 = Conv2D(256, (3, 3), activation='relu', padding='same')(conv3)
  maxpool3 = MaxPooling2D((2, 2), strides=(2, 2))(conv3)

  conv4 = Conv2D(512, (3, 3), activation='relu', padding='same')(maxpool3)
  conv4 = Conv2D(512, (3, 3), activation='relu', padding='same')(conv4)

  up1 = UpSampling2D((2, 2))(conv4)
  concat1 = concatenate([conv3, up1], axis=-1)
  conv5 = Conv2D(256, (3, 3), activation='relu', padding='same')(concat1)

  up2 = UpSampling2D((2, 2))(conv5)
  concat2 = concatenate([conv2, up2], axis=-1)
  conv6 = Conv2D(128, (3, 3), activation='relu', padding='same')(concat2)

  up3 = UpSampling2D((2, 2))(conv6)
  concat3 = concatenate([conv1, up3], axis=-1)
  outputs = Conv2D(n_classes, (1, 1), activation='softmax', padding='same')(concat3)

  model = Model(inputs, outputs)
  return model

model = create_fcn((256, 256, 3))
model.summary()
```

```
input_5 (InputLayer)        [(None, 256, 256, 3)]        0         []

conv2d_31 (Conv2D)          (None, 256, 256, 64)         1792      ['input_5[0][0]']

conv2d_32 (Conv2D)          (None, 256, 256, 64)         36928     ['conv2d_31[0][0]']

max_pooling2d_7 (MaxPoolin  (None, 128, 128, 64)         0         ['conv2d_32[0][0]']
g2D)

conv2d_33 (Conv2D)          (None, 128, 128, 128)        73856     ['max_pooling2d_7[0][0]']

conv2d_34 (Conv2D)          (None, 128, 128, 128)        147584    ['conv2d_33[0][0]']

max_pooling2d_8 (MaxPoolin  (None, 64, 64, 128)          0         ['conv2d_34[0][0]']
g2D)

conv2d_35 (Conv2D)          (None, 64, 64, 256)          295168    ['max_pooling2d_8[0][0]']

conv2d_36 (Conv2D)          (None, 64, 64, 256)          590080    ['conv2d_35[0][0]']

max_pooling2d_9 (MaxPoolin  (None, 32, 32, 256)          0         ['conv2d_36[0][0]']
g2D)

conv2d_37 (Conv2D)          (None, 32, 32, 512)          1180160   ['max_pooling2d_9[0][0]']

conv2d_38 (Conv2D)          (None, 32, 32, 512)          2359808   ['conv2d_37[0][0]']

up_sampling2d_7 (UpSamplin  (None, 64, 64, 512)          0         ['conv2d_38[0][0]']
g2D)

concatenate_7 (Concatenate  (None, 64, 64, 768)          0         ['conv2d_36[0][0]',
)                                                                   'up_sampling2d_7[0][0]']

conv2d_39 (Conv2D)          (None, 64, 64, 256)          1769728   ['concatenate_7[0][0]']

up_sampling2d_8 (UpSamplin  (None, 128, 128, 256)        0         ['conv2d_39[0][0]']
g2D)

concatenate_8 (Concatenate  (None, 128, 128, 384)        0         ['conv2d_34[0][0]',
)                                                                   'up_sampling2d_8[0][0]']

conv2d_40 (Conv2D)          (None, 128, 128, 128)        442496    ['concatenate_8[0][0]']

up_sampling2d_9 (UpSamplin  (None, 256, 256, 128)        0         ['conv2d_40[0][0]']
g2D)

concatenate_9 (Concatenate  (None, 256, 256, 192)        0         ['conv2d_32[0][0]',
)                                                                   'up_sampling2d_9[0][0]']

conv2d_41 (Conv2D)          (None, 256, 256, 34)         6562      ['concatenate_9[0][0]']

==================================================================================================
Total params: 6904162 (26.34 MB)
Trainable params: 6904162 (26.34 MB)
Non-trainable params: 0 (0.00 Byte)
```

```
elapsed_time = fit_model(model)
fcn_class_iou_dict = eval_model(model)
print(f'Time Elapsed: {elapsed_time}')
seg_sample(model)
```

DeepLab

O modelo DeepLab utiliza dilatações nas camadas convolucionais para aumentar o campo receptivo, melhorando a precisão da segmentação. Essa abordagem é particularmente eficaz para a captura de informações contextuais em uma área maior da imagem.

- Atrous (Dilated) Convolution: O DeepLab utiliza convoluções atrous (ou dilated convolutions) para aumentar o campo receptivo das camadas convolucionais sem reduzir a resolução espacial da entrada. Isso permite que a rede capture informações contextuais em várias escalas e resolva problemas de perda de detalhes que ocorrem com convoluções de tamanho fixo.
- ASPP (Atrous Spatial Pyramid Pooling): O ASPP é uma parte fundamental do DeepLab que ajuda a capturar informações contextuais em diferentes escalas. Ele utiliza múltiplas taxas de dilatação em paralelo para convoluções atrous e combina suas saídas. Isso permite que a rede capture informações contextuais em diferentes escalas espaciais.
- Backbone: O DeepLab pode ser construído com diferentes backbones, como ResNet, MobileNet, etc., para extrair características de nível mais alto. Esses backbones pré-treinados em grandes conjuntos de dados (como ImageNet) ajudam a melhorar o desempenho e a acelerar o treinamento.
- Pooling Espacial Através de Convoluções Atrous: O DeepLab também incorpora camadas de pooling espacial usando convoluções atrous. Isso ajuda a reduzir a resolução espacial da entrada para melhorar a eficiência computacional, enquanto mantém a capacidade de capturar informações contextuais em diferentes escalas.
- Camada de Saida de Convolução: A camada de saída do DeepLab geralmente consiste em uma convolução 1x1 para reduzir a dimensionalidade e produzir um mapa de segmentação com um número de canais igual ao número de classes de segmentação. A ativação Softmax é frequentemente usada para atribuir probabilidades de pertencimento a cada classe de segmentação para cada pixel.
- Uso de Funções de Perda Específicas: O DeepLab usa funções de perda apropriadas para tarefas de segmentação semântica, como a entropia cruzada.

```
def atrous_spatial_pyramid_pooling(inputs):
  dilations = [1, 6, 12, 18]

  conv1x1_1 = Conv2D(256, (1, 1), padding='same', activation='relu')(inputs)
  conv1x1_2 = Conv2D(256, (1, 1), dilation_rate=(dilations[0], dilations[0]), padding='same', acti
  conv1x1_3 = Conv2D(256, (1, 1), dilation_rate=(dilations[1], dilations[1]), padding='same', acti
  conv1x1_4 = Conv2D(256, (1, 1), dilation_rate=(dilations[2], dilations[2]), padding='same', acti
  conv1x1_5 = Conv2D(256, (1, 1), dilation_rate=(dilations[3], dilations[3]), padding='same', acti

  concatenated = concatenate([conv1x1_1, conv1x1_2, conv1x1_3, conv1x1_4, conv1x1_5], axis=-1)
  return concatenated

def create_deeplab(input_shape):
  backbone = MobileNetV2(input_shape=input_shape, include_top=False, weights='imagenet')

  aspp = atrous_spatial_pyramid_pooling(backbone.output)
  upsample = Conv2DTranspose(256, (3, 3), strides=(2, 2), padding='same', activation='relu')(aspp)
  outputs = Conv2D(n_classes, (1, 1), padding='same', activation='softmax')(upsample)

  model = models.Model(backbone.input, outputs)
  return model

```

```
23 model = create_deeplab((256, 256, 3))
```

```
block_14_depthwise_BN (Bat  (None, 8, 8, 960)           3840      ['block_14_depthwise[0][0]
chNormalization)

block_14_depthwise_relu (R  (None, 8, 8, 960)           0         ['block_14_depthwise_BN[0]
eLU)                                                              ]

block_14_project (Conv2D)   (None, 8, 8, 160)           153600    ['block_14_depthwise_relu[
                                                                  ]']

block_14_project_BN (Batch  (None, 8, 8, 160)           640       ['block_14_project[0][0]']
Normalization)

block_14_add (Add)          (None, 8, 8, 160)           0         ['block_13_project_BN[0][0
                                                                   'block_14_project_BN[0][0

block_15_expand (Conv2D)    (None, 8, 8, 960)           153600    ['block_14_add[0][0]']

block_15_expand_BN (BatchN  (None, 8, 8, 960)           3840      ['block_15_expand[0][0]']
ormalization)

block_15_expand_relu (ReLU  (None, 8, 8, 960)           0         ['block_15_expand_BN[0][0]
)

block_15_depthwise (Depthw  (None, 8, 8, 960)           8640      ['block_15_expand_relu[0][
iseConv2D)

block_15_depthwise_BN (Bat  (None, 8, 8, 960)           3840      ['block_15_depthwise[0][0]
chNormalization)

block_15_depthwise_relu (R  (None, 8, 8, 960)           0         ['block_15_depthwise_BN[0]
eLU)                                                              ]

block_15_project (Conv2D)   (None, 8, 8, 160)           153600    ['block_15_depthwise_relu[
                                                                  ]']

block_15_project_BN (Batch  (None, 8, 8, 160)           640       ['block_15_project[0][0]']
Normalization)

block_15_add (Add)          (None, 8, 8, 160)           0         ['block_14_add[0][0]',
                                                                   'block_15_project_BN[0][0

block_16_expand (Conv2D)    (None, 8, 8, 960)           153600    ['block_15_add[0][0]']

block_16_expand_BN (BatchN  (None, 8, 8, 960)           3840      ['block_16_expand[0][0]']
ormalization)

block_16_expand_relu (ReLU  (None, 8, 8, 960)           0         ['block_16_expand_BN[0][0]
)

block_16_depthwise (Depthw  (None, 8, 8, 960)           8640      ['block_16_expand_relu[0][
iseConv2D)

block_16_depthwise_BN (Bat  (None, 8, 8, 960)           3840      ['block_16_depthwise[0][0]
chNormalization)

block_16_depthwise_relu (R  (None, 8, 8, 960)           0         ['block_16_depthwise_BN[0]
eLU)                                                              ]
```

```
1 elapsed_time = fit_model(model)
2 deeplab_class_iou_dict = eval_model(model)
3 print(f'Time Elapsed: {elapsed_time}')
4 seg_sample(model)
```

PSPNet

A arquitetura PSPNet (Pyramid Scene Parsing Network) utiliza pirâmides de pooling para capturar informações contextuais em diferentes escalas, possibilitando uma compreensão mais abrangente da cena.

- Camada PSP (Pyramid Pooling Module): A característica central do PSPNet é a camada PSP, que captura informações contextuais em várias escalas espaciais. Ela divide a representação intermediária da imagem em várias regiões, calcula a média global ou a max-pooling em cada região e concatena essas informações para criar um vetor de contexto. Isso ajuda a rede a capturar informações de contexto em várias escalas, permitindo a segmentação precisa de objetos em diferentes tamanhos.
- Backbone: O PSPNet geralmente usa uma rede neural profunda pré-treinada, como ResNet ou VGG, como seu backbone para extrair características de nível mais alto. Esses backbones pré-treinados em grandes conjuntos de dados, como ImageNet, ajudam a melhorar o desempenho e a acelerar o treinamento.
- Camadas Convolutivas: Após a camada PSP, o PSPNet utiliza camadas convolutivas para refinar ainda mais a representação e produzir a saída de segmentação.
- Uso de Funções de Perda Específicas: O PSPNet usa funções de perda apropriadas para tarefas de segmentação semântica, como a entropia cruzada.

```
def pyramid_pooling_module(input_tensor, pool_sizes=[1, 2, 3, 6]):
  concat_layers = [input_tensor]

  for size in pool_sizes:
    pooled = AveragePooling2D(pool_size=(input_tensor.shape[1] // size, input_tensor.shape[2] // s
    conv = Conv2D(256, (1, 1), padding='same')(pooled)
    upsampled = UpSampling2D(size=(input_tensor.shape[1] // size, input_tensor.shape[2] // size))(
    concat_layers.append(upsampled)

  return concatenate(concat_layers, axis=-1)

def create_pspnet(input_shape):
  inputs = Input(shape=input_shape)

  backbone = ResNet50(include_top=False, weights='imagenet', input_tensor=inputs)

  encoder_output = backbone.get_layer('conv4_block6_out').output

  psp = pyramid_pooling_module(backbone.output)

  x = Conv2D(512, (3, 3), padding='same', activation='relu')(psp)
  x = BatchNormalization()(x)
  x = Conv2D(256, (1, 1), padding='same', activation='relu')(x)
  x = BatchNormalization()(x)

  outputs = Conv2D(n_classes, (1, 1), activation='softmax', padding='same')(x)

  model = Model(inputs=backbone.input, outputs=outputs)
  return model

model = create_pspnet((256, 256, 3))
model.summary()
```

```
conv2_block3_1_conv (Conv2  (None, 64, 64, 64)          16448     ['conv2_block2_out[0][0]']
D)

conv2_block3_1_bn (BatchNo  (None, 64, 64, 64)          256       ['conv2_block3_1_conv[0][0
rmalization)

conv2_block3_1_relu (Activ  (None, 64, 64, 64)          0         ['conv2_block3_1_bn[0][0]'
ation)

conv2_block3_2_conv (Conv2  (None, 64, 64, 64)          36928     ['conv2_block3_1_relu[0][0
D)

conv2_block3_2_bn (BatchNo  (None, 64, 64, 64)          256       ['conv2_block3_2_conv[0][0
rmalization)

conv2_block3_2_relu (Activ  (None, 64, 64, 64)          0         ['conv2_block3_2_bn[0][0]'
ation)

conv2_block3_3_conv (Conv2  (None, 64, 64, 256)         16640     ['conv2_block3_2_relu[0][0
D)

conv2_block3_3_bn (BatchNo  (None, 64, 64, 256)         1024      ['conv2_block3_3_conv[0][0
rmalization)

conv2_block3_add (Add)      (None, 64, 64, 256)         0         ['conv2_block2_out[0][0]',
                                                                   'conv2_block3_3_bn[0][0]'

conv2_block3_out (Activati  (None, 64, 64, 256)         0         ['conv2_block3_add[0][0]']
on)

conv3_block1_1_conv (Conv2  (None, 32, 32, 128)         32896     ['conv2_block3_out[0][0]']
D)

conv3_block1_1_bn (BatchNo  (None, 32, 32, 128)         512       ['conv3_block1_1_conv[0][0
rmalization)

conv3_block1_1_relu (Activ  (None, 32, 32, 128)         0         ['conv3_block1_1_bn[0][0]'
ation)

conv3_block1_2_conv (Conv2  (None, 32, 32, 128)         147584    ['conv3_block1_1_relu[0][0
D)

conv3_block1_2_bn (BatchNo  (None, 32, 32, 128)         512       ['conv3_block1_2_conv[0][0
rmalization)

conv3_block1_2_relu (Activ  (None, 32, 32, 128)         0         ['conv3_block1_2_bn[0][0]'
ation)

conv3_block1_0_conv (Conv2  (None, 32, 32, 512)         131584    ['conv2_block3_out[0][0]']
D)

conv3_block1_3_conv (Conv2  (None, 32, 32, 512)         66048     ['conv3_block1_2_relu[0][0
D)

conv3_block1_0_bn (BatchNo  (None, 32, 32, 512)         2048      ['conv3_block1_0_conv[0][0
rmalization)
```

```
elapsed_time = fit_model(model)
pspnet_class_iou_dict = eval_model(model)
print(f'Time Elapsed: {elapsed_time}')
seg_sample(model)
```

Salvar como PDF

[ ] ↳ *2 cells hidden*